

Learning Progress Review - Week 10

29/10- 5/12

Group 5 | Seru!

Table of contents

01

Data Preprocessing II

Handling Text Data

02


Supervised I

Classification, logistic regression,
KNN, Decision Tree, Ensemble
Learning, Evaluation Metrics

03

Supervised II

Ensemble Learning,
Evaluation Metrics,
Imbalance Data Handling






01

Data Preprocessing I

Handling Text Data



Text Data Handling



2. Text tokenization

Menjadikan text berupa potongan- potongan kata.

```
import nltk
from nltk.tokenize import word_tokenize

# Melakukan tokenisasi kata menggunakan word_tokenize
tokens = word_tokenize(cleaned_text)

# Menampilkan hasil tokenisasi
print(tokens)
```

['yesterday', 's', 'intense', 'match', 'between', 'the', 'two', 'rival', 'teams', 'kept', 'the', 'crowd', 'on', 'the', 'edge', 'of', 'their', 'seats']

1. Cleansing & tokenization

Membersihkan format text dari special character

```
pattern = r'[^\\w\\s][\\d]'
```

Menggantikan tanda baca dan angka dengan spasi
cleaned_text = re.sub(pattern, ' ', text)

Menghapus spasi berlebih setelah penggantian
cleaned_text = re.sub(r'\\s+', ' ', cleaned_text).strip()

cleaned_text

'Yesterday s intense match between the two rival teams kept the crowd on the edge of their seats'

3. Stop words removal

```
from nltk.corpus import stopwords

stop_words = set(stopwords.words('english'))

filtered_words = []
for w in tokens:
    if w not in stop_words:
        filtered_words.append(w)

print(filtered_words)
```

From this: ['Yesterday', 's', 'intense', 'match', 'between', 'the', 'two', 'rival', 'teams', 'kept', 'the', 'crowd', 'on', 'the', 'edge', 'of', 'their', 'seats']

To this: ['Yesterday', 'intense', 'match', 'two', 'rival', 'teams', 'kept', 'crowd', 'edge', 'seats']

Text Data Handling

4. Stemming

Menghapus akhiran, awalan, atau sisipan dari kata untuk mendapatkan bentuk dasar atau akar kata.

```
from nltk.stem import PorterStemmer

ps = PorterStemmer()

stemmed_words = []
for w in filtered_words:
    stemmed_words.append(ps.stem(w))

print(stemmed_words)
```

['yesterday', 'intens', 'match', 'two', 'rival', 'team', 'kept', 'crowd', 'edg', 'seat']

5. Lemmatization

Mengubah kata ke bentuk dasar atau akar kata yang sesuai dalam kamus.

Stemming vs Lemmatization



```
from nltk.stem.wordnet import WordNetLemmatizer

lem = WordNetLemmatizer()

lemm_words = []
for w in filtered_words:
    lemm_words.append(lem.lemmatize(w, 'v'))

print(lemm_words)
```

['yesterday', 'intense', 'match', 'two', 'rival', 'team', 'keep', 'crowd', 'edge', 'seat']

6. Vectorization

Proses mengubah teks menjadi representasi numerik dalam bentuk vektor.



7. Bag of Words (BoW)

Menghitung frekuensi kemunculan kata-kata dalam dokumen dan menghasilkan vektor numerik yang merepresentasikan frekuensi tersebut.

Doc 1: "I love dogs".

Doc 2: "I hate dogs and knitting".


Doc 3: "Knitting is my hobby and my passion"

	I	love	dogs	hate	and	knitting	is	my	hobby	passion
Doc 1	1	1	1							
Doc 2	1		1	1	1	1				
Doc 3					1	1	1	2	1	1

Text Data Handling

8. N-Gram

Menghitung frekuensi n-gram (misalnya, bigram atau trigram) dalam teks dan menghasilkan vektor numerik yang merepresentasikan frekuensi tersebut.



Bigram (2-gram)

Doc 1: "I love dogs"

Doc 2: "I hate dogs and knitting"

Doc 3: "Knitting is my hobby and my passion"

	and knitting	and my	dogs and	hate dogs	hobby and	is my	knitting is	love dogs	my hobby	my passion
Doc 1	0	0	0	0	0	0	0	1	0	0
Doc 2	1	0	1	1	0	0	0	0	0	0
Doc 3	0	1	0	0	1	1	1	0	1	1

9. TF-IDF

Term Frequency-Inverse Document Frequency. Untuk menilai tingkat pentingnya suatu kata atau frasa dalam suatu dokumen atau kumpulan dokumen.

TF menghitung seberapa sering kata tertentu muncul dalam sebuah dokumen. Semakin sering muncul, semakin tinggi nilai TF-nya.

IDF menghitung seberapa umum kata tersebut di seluruh dokumen yang tersedia. Semakin ditemukan di banyak dokumen, nilai IDF-nya menurun, karena dianggap kurang penting.

$$w_{x,y} = tf_{x,y} \times \log \left(\frac{N}{df_x} \right)$$

TF-IDF

$tf_{x,y}$ = frequency of x in y / (total number of terms in y)
Term x within document y
 df_x = number of documents containing x
N = total number of documents

BoW		I	love	dogs	hate	and	knitting	is	my	hobby	passion
	Doc 1	1	1	1	0	0	0	0	0	0	0
	Doc 2	1	0	1	1	1	1	0	0	0	0
	Doc 3	0	0	0	0	1	1	1	2	1	1

IDF	0.18	0.48	0.18	0.48	0.18	0.18	0.48	0.48	0.48	0.48
-----	------	------	------	------	------	------	------	------	------	------


TF-IDF		I	love	dogs	hate	and	knitting	is	my	hobby	passion
	Doc 1	0.059	0.159	0.059	0.000	0.000	0.000	0.000	0.000	0.000	0.000
	Doc 2	0.035	0.000	0.035	0.035	0.035	0.035	0.000	0.000	0.000	0.000
	Doc 3	0.000	0.000	0.000	0.000	0.025	0.025	0.025	0.050	0.025	0.025

Text Data Handling

10. Word Embedding

Untuk merepresentasikan kata-kata dalam bentuk vektor dalam ruang multidimensional yang berisi informasi tentang arti, makna, dan hubungan antar kata tersebut.

Banyak digunakan dalam aplikasi NLP seperti analisis teks, klasifikasi dokumen, pemodelan bahasa, dan mesin pencari.






02

Supervised I

Classification, logistic regression, KNN, Decision Tree



Gambaran Umum



Pengertian

Merupakan bagian dari metode di dalam Machine Learning.


Bertujuan untuk membentuk model atau formula yang dapat digunakan untuk memprediksi suatu nilai berdasarkan data latih (train data) yang sudah ada.

Disebut metode pembelajaran terawasi, karena model sangat ditentukan oleh input (feature object) dan output (label object) untuk mendapatkan prediksi yang akurat.



Cara Kerja Dasar

1. Model dilatih/diajarkan menggunakan dataset pelatihan yang memiliki input dan output yang benar.
2. Model belajar seiring waktu.
3. Akurasi diukur melalui fungsi kerugian (Loss Function) hingga kesalahan diminimalkan.



Tipe Supervised Learning

Klasifikasi (Classification)


Tujuan: Untuk memprediksi suatu kelas atau label dari objek informasi berdasarkan data latih.

Fungsi: Menetapkan data uji ke dalam kategori tertentu secara akurat.

- **Logistic Regression:** Digunakan untuk memprediksi objek ke dalam kelas-kelas. Menghasilkan output probabilitas (antara 0 hingga 1). Contoh: Kelayakan kredit. * Naive Bayes: Menggunakan prinsip Teorema Bayes. Mengasumsikan bahwa masing-masing feature adalah independen.
- **K-NN (K-Nearest Neighbors):** Mengklasifikasikan data baru ke kelas terdekat berdasarkan jarak data baru dengan k terdekat. * Decision Tree: Model prediksi menggunakan struktur pohon atau struktur berhirarki, berdasarkan aturan-aturan keputusan. Terdiri dari Root Node, Branches, dan Leaf Node. * Support Vector Machines (SVM), lainnya.

Regresi (Regression)

- **Tujuan:** Untuk memahami hubungan antara variabel terikat dan variabel bebas.
- **Fungsi:** Mengidentifikasi nilai riil (seperti gaji, berat, penjualan, dll.).
- **Contoh Algoritma:** Regresi linier, Regresi logistik, Regresi polinomial.



Algoritma Lanjutan




Random Forest

- Pengembangan dari Decision Tree.
- **Prinsip:** Dibangun dari kombinasi beberapa decision tree.
- **Cara Kerja:** Setiap decision tree menghasilkan output, lalu dilakukan voting untuk menentukan hasil mayoritas dari seluruh pohon.



Neural Network

- Terinspirasi dari cara kerja jaringan saraf manusia.
- **Struktur:** Tersusun atas lapisan-lapisan (layers) neuron saraf.
- Data diproses di setiap lapisan dan diteruskan ke lapisan berikutnya hingga mencapai lapisan terakhir (layer output).






03

Supervised II

Ensemble Learning, Evaluation Metrics, Imbalance Data Handling




Ensemble Learning

1. Bagging (Bootstrap Aggregating)

Bagging adalah metode untuk membuat model machine learning dengan membuat model machine learning yang lemah dari data tersebut secara paralel yang kemudian digabungkan secara rata-rata atau voting sehingga model memiliki performance yang kuat.

1. Boosting

Boosting adalah metode untuk membuat model machine learning dengan melakukan improvement artinya model 1 yang telah dibuat akan dilakukan improvement secara berurutan untuk menghasilkan model yang maksimal.



Source Image: <https://medium.com/analytics-vidhya/ensemble-methods-bagging-boosting-and-stacking-28d006708731>

Random Forest dan XGBoost

1. Random Forest

Algoritma machine learning yang bekerja dengan membangun banyak decision tree secara acak, kemudian menggabungkan hasilnya untuk menghasilkan prediksi yang lebih akurat dan stabil. Algoritma ini dapat digunakan untuk masalah klasifikasi maupun regresi dan sering diadopsi karena fleksibilitasnya.

1. XGBoost

Algoritma ini menggunakan metode gradient boosting untuk menggabungkan banyak pohon keputusan lemah menjadi satu model kuat, dengan setiap pohon berikutnya fokus untuk memperbaiki kesalahan dari model sebelumnya.

Evaluation Metrics

1. Akurasi

Metrik adalah pengukuran untuk mengukur banyak data yang diprediksi dengan benar.

$$\text{Akurasi} = \frac{\text{Jumlah observasi yang diprediksi dengan benar}}{\text{Total semua observasi}}$$

$$\text{Error} = 1 - \text{Akurasi}$$

1. Confusion Matrix

Tabel evaluasi performa model klasifikasi machine learning yang membandingkan hasil prediksi model dengan nilai sebenarnya (aktual) untuk melihat seberapa akurat model tersebut, dengan mengkategorikan prediksi menjadi empat jenis: True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN), yang kemudian digunakan untuk menghitung metrik seperti presisi, recall dan specify.

Evaluation Metrics

Table Confusion Matrix

Nilai Aktual

Nilai Prediksi

	Positive	Negative
Positive	TP	FP
Negative	FN	TN

a. Presisi

$$Presisi = \frac{TP}{TP + FP}$$

a. Recall

$$Recall = \frac{TP}{TP + FN}$$


a. Specify

$$Specifity = \frac{TN}{TN + FP}$$

3. AUC dan ROC

AUC (Area Under the Curve) adalah area di bawah kurva ROC. Nilai dari AUC berkisar antara 0 sampai 1. Jika nilai AUC >0.5 maka model dianggap sangat baik, jika AUC = <0.5 maka model dianggap lemah.

ROC (Receiver Operating Characteristic Curve) adalah plot probabilitas yang menggambarkan kinerja model klasifikasi biner pada berbagai ambang batas (threshold) keputusan.



Imbalance Data Handling

1. UnderSampling

Metode mengurangi sampel mayoritas untuk mengatasi imbalance data.



2. OverSampling

Metode mengambil semua kelas minoritas untuk mengatasi imbalance data.



3. SMOTE (Synthetic Minority Oversampling Technique)

Metode dengan melakukan sintesis data minoritas dengan cara menambah data baru berdasarkan kedekatan dengan data minoritas.

Synthetic Minority Oversampling Technique





Thank You
